

Zoekalgoritmen

Bachelor IT

Sven Mariën

(sven.marien01@ap.be)

Zoekalgoritme: waarom ?

- We willen nagaan of een element aanwezig is een lijst
- We willen de plaats kennen van een bepaald element in een lijst
- We willen nagaan of een bepaald element meermaals aanwezig is in de lijst.
- ...



Overzicht

- **Lineair search / Sequential search**
- **Binary search**
- **Hash table**

Lineair search

- Ook wel “sequential” search genoemd.
- Algoritme:
 - Start bij het begin van de lijst
 - Vergelijk met de te zoeken waarde
 - Ga naar het volgende element en herhaal ofwel tot
 - de waarde gevonden werd.
 - het einde van de lijst is bereikt.

3	6	7	10	4	12	9	5	8
---	---	---	----	---	----	---	---	---


1.) let's find 5 with linear search algorithm

Lineair search

- Dit algoritme hadden we ook reeds gebruikt bij de linked list om een element op te zoeken
- Return waarde:
 - **True/false:** het element is aanwezig / niet-aanwezig
 - **Index** : plaats van het element in de lijst
 - **Node:** in geval van een linked list
- Voordeel:
 - Eenvoudig algoritme
 - De lijst hoeft niet gesorteerd te zijn.
- Nadeel:
 - In het slechtste geval moet de volledige lijst doorlopen worden => time complexity: $O(n)$

Binary Search

- Andere benamingen: “half-interval search”, “logarithmic search”
- Voorwaarde: de lijst **moet** reeds gesorteerd zijn !
- Algoritme:
 - Neem het **middelste** element in de lijst
 - **Vergelijk** met de **te zoeken waarde**
 - Indien de **gevonden waarde** $<$ **te zoeken**:
 - Neem de **rechter helft** en start opnieuw
 - Indien de **gevonden waarde** $>$ **te zoeken**:
 - Neem de **linker helft** en start opnieuw



Binary Search

- “Divide and conquer” principe
 - Steeds de lijst in de helft delen
 - Werkt dus enkel met arrays.
 - Recursie !
- Voordeel:
 - Het is een snel algoritme: **$O(\log n)$**
- Nadeel:
 - De lijst moet reeds gesorteerd zijn.
 - Niet bruikbaar met linked lists.


Binary Search / Binary Search Tree

- Werken op dezelfde manier
- Hebben dus ook dezelfde efficiëntie (indien het om een “balanced tree” gaat).
- Beiden: **$O(\log n)$** time complexity

N	Max. aantal compares
7	3
15	4
512	9
1.000.000	20



www.mathwarehouse.com



www.mathwarehouse.com

Kunnen we nog beter doen ?

- Wat is de snelste manier om in een array te zoeken ?
- Stel: ik heb een lijstje met volgende elementen:

- 2, 5, 6, 11, 13, 14, 15, 18

2	5	6	11	13	14	15	18
0	1	2	3	4	5	6	7

- Wat als ik mijn array echter op deze manier zou opvullen ?

0	0	2	0	0	5	6	0	0	0	0	11	0	13	14	15	0	0	18	0
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19

- Wat is de performantie dan om een element op te zoeken ?
 - Time complexity: $O(1)$!!! 😊
 - Maar.... Space Complexity: $O(\max)$ ☹️

Hashing

- Wat is hashing ?

Hashing is the transformation of a string of [characters](#) into a usually shorter fixed-length value or key that represents the original string. Hashing is used to index and retrieve items in a [database](#) because it is faster to find the item using the shorter hashed key than to find it using the original value. It is also used in many [encryption](#) algorithms.



- Hashing is “one way” !

Original string	“Hash value”
“hallo”	287
“dit is een tekst”	498
“hello”	189
“AP hogeschool”	344

Hashing

- Gekende algoritmes:
 - SHA (SHA-1, SHA-2)
 - MD-4, MD-5
 - ...
- Toepassingen:
 - **Datastructuren:** Hashtable, Dictionary,...
 - **Authenticatie:** wachtwoorden worden nooit als “plain tekst” bewaard in de databank.
 - **Patronen** zoeken in teksten (bv. plagiaatdetectie)
 - ...



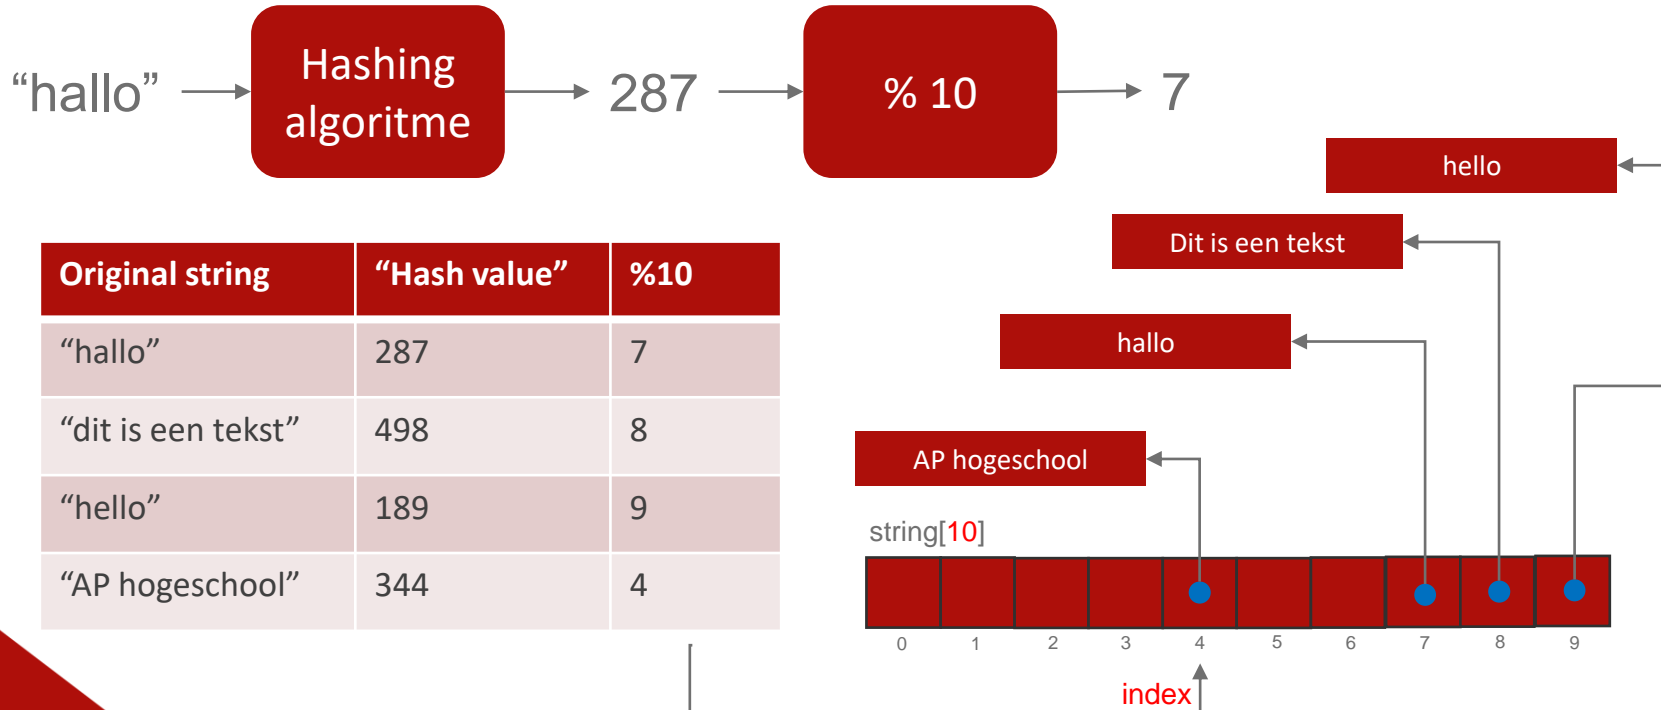
Zoeken mbv. "hashing"

- Hoe kunnen we de hash value nu concreet gebruiken ?
 - We zouden de hash value als index kunnen nemen van onze array.
 - Dit geeft echter nog steeds veel lege ruimten in de array
- Extra toevoeging:
 - gebruik van modulo operator (%)

Original string	"Hash value"
"hallo"	287
"dit is een tekst"	498
"hello"	189
"AP hogeschool"	344

Hashing + Modulo operator = "Hash table"

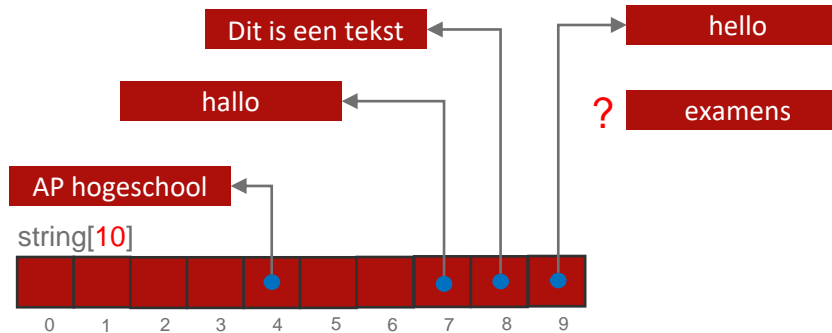
- Vb. ik verwacht max. **10** elementen in mijn lijst => % **10**



Hashing collisions

- Het zou kunnen dan het hashing algoritme dezelfde “hash value” geeft voor verschillende “input”
- Dit noemt men “**collisions**”.

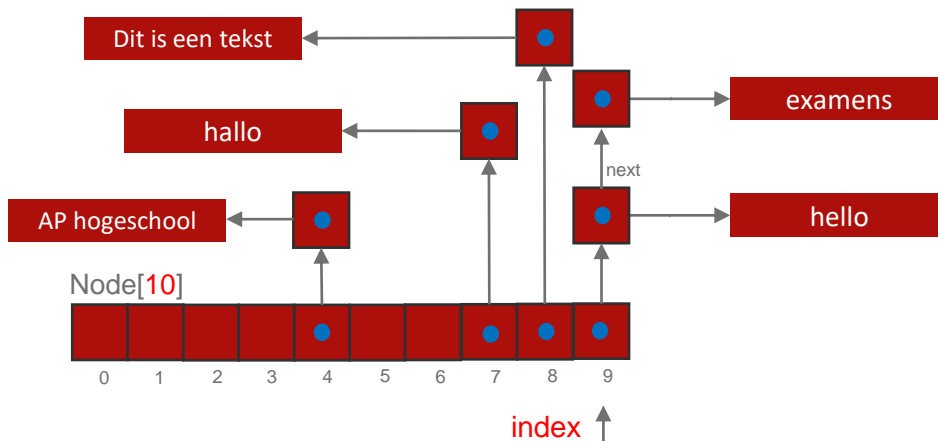
Original string	“Hash value”	%10
“hallo”	287	7
“dit is een tekst”	498	8
“hello”	189	9
“AP hogeschool”	344	4
“examens”	189	9



Hoe collisions vermijden / oplossen ?


- Een goed hashing algoritme zorgt voor weinig of geen collisions
- Toch collisions ?
 - Werken met **array** + bijkomende **linked list(s)**

Original string	"Hash value"	%10
"hallo"	287	7
"dit is een tekst"	498	8
"hello"	189	9
"AP hogeschool"	344	4
"examens"	189	9



Vergelijking zoekalgoritmes

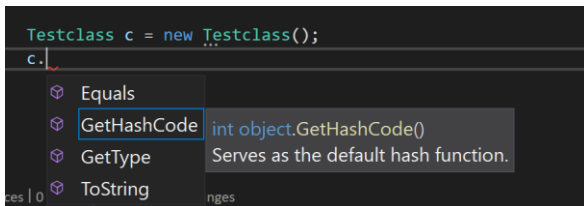
Zoekalgoritme	Time Complexity	Array	Linked List
Lineair / Sequential search	$O(n)$	✓	✓
Binary Search	$O(\log n)$	✓	X
Hash table (*)	$O(1)$	✓	X



(*) Collisions zorgen ervoor dat de time complexity slechter wordt, doordat er extra bijkomende opzoeken moeten gebeuren.

c# - GetHashCode()

- Op de base class 'object'
 - bevinden zich 4 methodes
 - GetHashCode() zal een 'default' hashcode geven voor eender welk object of type in c#.
 - Uiteraard kan je deze overschrijven



```
int getal = 123;
Console.WriteLine($"{getal} geeft een hashcode: {getal.GetHashCode()}");

string text = "123";
Console.WriteLine($"{text} geeft een hashcode: {text.GetHashCode()}");

Auto auto = new Auto()
{
    AantalKm = 10000,
    Bouwjaar = 2005,
    Brandstof = Brandstof.Waterstof,
    Kleur = "Rood",
    Model = "Ferrari F40"
};
Console.WriteLine($"{auto} geeft een hashcode: {auto.GetHashCode()}");

Auto auto2 = new Auto()
{
    AantalKm = 20000,
    Bouwjaar = 2005,
    Brandstof = Brandstof.Electriciteit,
    Kleur = "Groen",
    Model = "Ferrari F40"
};
Console.WriteLine($"{auto2} geeft een hashcode: {auto2.GetHashCode()}");
```

```
Hello World!
123 geeft een hashcode:123
123 geeft een hashcode:1747292503
Ferrari F40 (kleur: Rood, bj:2005, km:10000) geeft een hashcode: 58225482
Ferrari F40 (kleur: Groen, bj:2005, km:20000) geeft een hashcode: 54267293
```

